

AIMER: 基于跨模态情绪对齐的音乐情感识别系统



上海交通大学自动化与感知学院

针对传统音乐推荐系统忽视用户即时情绪需求的问题，本文构建了一种基于Valence–Arousal (VA) 模型的跨模态情绪感知与音乐推荐系统。方法上，分别从音乐音频与用户文本中回归连续VA 情绪坐标，并在统一情绪空间内实现跨模态对齐与情绪驱动推荐，支持情绪共鸣与情绪调节等多种策略。实验结果表明，所提出的情绪建模方法在准确性与稳定性上表现良好，系统能够直观、可解释地完成从情绪感知到音乐推荐的完整闭环，为情绪驱动型推荐系统提供了一种可行方案。

课程信息: 人工智能算法实践
提交日期: 2026 年1 月17 日

Contents

1 引言: 问题背景与项目目标	2
2 相关工作: 现有技术基础及缺口	2
3 音乐情绪识别模块	3
3.1 方法设计	3
3.2 实验设置	3
3.3 结果与分析	4
4 文本情绪识别模块	5
4.1 方法设计	5
4.2 实验设置	5
4.3 结果与分析	6
5 跨模态情绪对齐与推荐模块	12
5.1 方法设计	12
5.2 实验设置	13
5.3 结果与分析	13
6 系统整合与可视化展示 (GUI)	13
6.1 界面布局	13
6.2 私有音乐库管理	14
6.3 可解释性与反馈	14
7 总结与展望	14
8 小组分工	15
参考文献	15

1 引言：问题背景与项目目标

随着数字音乐平台的快速发展，用户可以轻易获取海量音乐资源，但“如何在合适的时刻听到合适的音乐”仍然是一个尚未被充分解决的问题。现有主流音乐推荐系统大多基于协同过滤或历史行为建模，其核心目标是预测用户“可能喜欢什么”，而非理解用户“此刻需要什么”。然而在真实使用场景中，人们打开音乐应用的动机往往具有显著的情绪导向性，例如缓解焦虑、安抚情绪、提升兴奋度或维持当下心境。这种以情绪为中心的音乐需求与传统兴趣导向推荐机制之间存在明显鸿沟。

在情绪计算领域，Valence–Arousal (VA) 模型因其连续性和心理学可解释性，被广泛用于描述人类情绪状态。Valence 表示愉悦程度，Arousal 表示唤醒水平，两者共同构成一个二维情绪空间，能够统一刻画“快乐、悲伤、紧张、平静”等多种心理状态。近年来，随着深度学习在语音、音乐和自然语言处理中的发展，从音频信号或文本语义中直接回归VA 值已成为可行技术路径。这为跨模态情绪理解与情绪驱动推荐系统提供了基础条件。

然而，现有研究通常将音乐情绪识别与文本情绪分析视为彼此独立的任务，很少在系统层面将两者统一到同一情绪空间中进行交互式应用。即便在少数情绪推荐工作中，推荐策略也多采用静态规则或离散情绪标签，缺乏对“情绪调节过程”的建模与可视化支持。这使得系统难以回答一个关键问题：当用户情绪处于某一状态时，音乐究竟是在“陪伴”还是在“引导”，以及这种变化在情绪空间中如何体现。

基于上述背景，本项目旨在构建一个以Valence–Arousal 模型为核心的跨模态情绪感知与音乐推荐系统，联合音乐情绪识别 (MER)、文本情绪识别以及跨模态情绪对齐与调节机制，实现从“用户自然语言输入”到“个性化音乐情绪引导”的完整闭环。具体而言，系统首先从用户文本中推断其当前情绪坐标，同时对音乐库中的每首曲目进行VA 情绪建模；随后在统一的情绪空间内，根据不同推荐策略（共鸣或调节）计算目标情绪位置，并选择最匹配的音乐集合进行推荐。

除了算法层面的实现，本项目还特别强调情绪计算过程的可视化与可解释性。通过在GUI 中将用户情绪、音乐情绪与推荐轨迹映射到同一二维平面，并结合热力图、动画与情绪标签，系统将抽象的情绪计算转化为直观的交互体验。这不仅提升了用户对推荐结果的理解，也为情绪驱动推荐系统的设计提供了新的工程范式。

综上，本项目的目标不仅是构建一个可运行的音乐推荐系统，更是探索如何将多模态情绪计算、心理学模型与交互式可视化有机融合，为情绪感知型智能系统提供可复现、可解释且具有实际应用价值的完整解决方案。

2 相关工作：现有技术基础及缺口

音乐情绪识别 (Music Emotion Recognition, MER) 作为音乐信息检索的一个重要子任务，在过去十多年里得到了广泛关注。早期方法主要基于人工设计的声学特征，如Mel 频率倒谱系数 (MFCC)、谱质心、节奏等，以及简单的分类器或回归模型（如支持向量机、随机森林），用于估计音乐的离散情绪标签或连续情绪强度。这种特征工程结合机器学习的策略在早期MER 研究中非常典型，但往往依赖于手工特征的诊断能力。随着深度学习的广泛应用，研究者开始利用卷积神经网络 (CNN)、卷积循环神经网络 (CRNN) 等端到端模型直接从谱图、Mel 频谱等时频表示中自动学习情绪相关的特征表示，从而提升了情绪回归与分类的性能。近年来的一些综述指出，基于深度学习的MER 方法已成为主流，并且在多个数据集上取得了优异表现，这表明自动特征学习在复杂情绪映射任务中具有显著优势。深度MER 研究也开始结合注意力机制或多模态融合策略以进一步提升性能。[1]

针对文本情绪识别 (Textual Emotion Recognition)，传统工作通常依赖情绪词典 (lexicon-based) 或基于语言规则的弱监督方法，将词汇极性组合用于情绪分类，这在早期情感分析研究中颇为常见。然而，仅依赖词汇级别规则的方式通常难以处理上下文语义与修辞结构信息。随着深度学习的发展，基于循环神经网络 (如LSTM) 及Transformer 的模型 (例如BERT) 在文本情绪判定任务中获得了显著提升，能够捕获更丰富的语义上下文，并在多个benchmark 数据集上实现更高准确率和更细粒度的情绪表示。最新的综述也指出，随着预训练语言模型的出现，文本情绪识别已向连续情绪预测甚至是面向VA 空间建模的方向发展，这使得文本情绪不仅限于极性分类，还能表达更细致的情绪强度和维度。[2]

尽管上述研究在单一模态的情绪识别任务中均取得了重要进展，但跨模态情绪对齐仍然是一个具有挑战性的研究方向。大多数现有工作主要处理单一模态数据，或者在离散标签层面尝试将不同模态的情绪信息对齐，而缺乏统一的连续情绪空间作为桥梁来同时刻画来自文本与音频的情绪表达。这种缺乏连续空间对齐与可视化支持的策略限制了系统在实际多模态推荐与交互应用中的表现。基于此，本项目提出在统一

的Valence–Arousal 情绪空间内，同时对文本与音乐进行情绪建模，并结合可视化界面展示，使多模态情绪信息在语义和空间层面实现一致性，有望改善推荐准确性与用户交互体验，从而推动跨模态情绪推荐系统的发展。^[3]

3 音乐情绪识别模块

音乐情绪识别（Music Emotion Recognition, MER）模块旨在从原始音频信号中自动提取情绪信息，并将音乐映射到连续的Valence–Arousal（VA）二维情绪空间中。该模块通过融合国际开源情绪音乐数据集与自主构建的情绪标注数据集，形成了规模充足、分布多样的训练语料，从而实现对音乐情绪的高精度建模与预测。

3.1 方法设计

本模块采用深度卷积神经网络对音乐的时频特征进行建模，并通过门控多专家结构实现对不同情绪区域的精细回归。

特征提取与增强 系统首先将mp3 等格式的音频统一重采样至22,050 Hz，并对信号进行短时傅里叶变换（STFT），得到时频表示。基于STFT 结果构建128 维梅尔频谱（Mel-spectrogram），记为

$$\mathbf{M}(t, f)$$

其中 t 表示时间帧， f 表示梅尔频率通道。为增强对节奏与动态变化的建模能力，进一步计算其一阶差分（Delta）和二阶差分（Delta–Delta），最终将三者沿通道维拼接，形成三通道输入张量：

$$\mathbf{X} = [\mathbf{M}, \Delta\mathbf{M}, \Delta^2\mathbf{M}].$$

该表示能够同时刻画音色、节奏变化与能量动态，是情绪感知的关键特征。

神经网络结构 主干网络采用引入通道注意力机制的残差卷积结构（SE-ResNet）。在每个残差块中，通过Squeeze-and-Excitation（SE）模块对不同频谱通道赋予自适应权重，使模型能够重点关注对情绪表达贡献更大的声学区域，从而提升特征表示的判别性。

门控多专家回归（Gated MoE） 为了适应VA 空间中不同象限的非线性分布特征，模型在高层特征之后引入门控多专家（Mixture of Experts, MoE）结构。设特征提取网络输出的全局语义向量为 $\mathbf{h}$ ，门控网络 $G(\cdot)$ 输出四个象限对应的权重：

$$\mathbf{g} = G(\mathbf{h}), \quad \sum_{i=1}^4 g_i = 1.$$

每个专家网络 $E_i(\cdot)$ 输出一个VA 预测 $\mathbf{y}_i = (V_i, A_i)$ ，最终预测结果为加权和：

$$(V, A) = \sum_{i=1}^4 g_i \cdot \mathbf{y}_i,$$

其中 V 表示愉悦度（Valence）， A 表示唤醒度（Arousal），并统一归一化到 $[0, 1]$ 区间。

接口封装 模型在完成训练后被封装为predict_emotion 接口，可对本地音乐库进行毫秒级批量推理，为后续构建用户个人音乐情绪库提供底层支持。

3.2 实验设置

多源数据集构建 训练数据由开源情绪音乐数据集（如DEAM、PMemo）与自主构建的audiolist数据集共同组成。自建数据集通过对大量音乐进行物理特征分析（能量强度、频谱亮度、节奏密度等）并结合人工校验生成VA标注，形成“音乐名_V_A_类别”的统一格式。训练中采用Soft-Quadrant Labeling方法，将象限标签转化为概率分布，以缓解情绪边界处的标注歧义。

数据预处理与增强 模型以10秒音频片段为输入。训练阶段采用随机裁剪（Random Crop）与频谱遮挡（SpecAugment）增强样本多样性，验证阶段则采用中心裁剪（Center Crop）以保证评估的一致性。

训练配置 模型采用AdamW优化器，初始学习率设为 1×10^{-3} ，批次大小为16。总损失函数由三部分组成：

$$\mathcal{L} = \mathcal{L}_{\text{SmoothL1}} + \lambda_1 \mathcal{L}_{\text{KL}} + \lambda_2 \mathcal{L}_{\text{Decorr}},$$

其中SmoothL1Loss用于VA回归精度，KLDivLoss用于象限分布约束，Decorrelation Loss用于降低V与A之间的耦合性。

3.3 结果与分析

定量评估 利用evaluate_scientific.py对模型进行系统评估，结果如表1所示。

Table 1 音乐情绪回归性能评估

维度	MAE	RMSE	R ²	Pearson
Valence	0.0269	0.0343	0.6226	0.7961
Arousal	0.0362	0.0455	0.6952	0.8589

结果表明，模型在两个维度上均具有较高的相关性和拟合能力，尤其在Arousal维度上表现尤为稳定。

分布与稳定性分析 图1展示了预测值与真实标注在VA空间中的散点分布，可以观察到模型输出覆盖了“狂欢、高唤醒”“治愈、低唤醒”“忧伤”“愤怒”等主要情绪区域，且整体分布与真实标签高度一致。




Figure 1 预测VA与真实VA的分布对比散点图

批量应用验证 通过运行batch_test_audiolist.py，系统可对用户本地数百首音乐进行自动VA预测与重命名，并按情绪象限自动归类到不同子目录中（如低愉悦-低唤醒到高愉悦-高唤醒）。这一结果表明，该模块已具备支撑大规模个人音乐情绪库构建的工程可用性，为后续跨模态情绪对齐与推荐提供了高质量的音乐情绪基础。

4 文本情绪识别模块

本章介绍本项目中文本情绪标注模块的设计与实现。该模块旨在将用户评论文本映射到连续的情绪空间中，为后续音乐音频情绪预测与跨模态情绪对齐提供可靠的监督信号。具体而言，本章围绕Valence–Arousal (VA) 情绪模型，分别探讨了基于词典的传统方法与基于BERT 的深度学习方法，并在此基础上构建了中英文情绪数据集，同时对模型的可解释性进行了分析。

4.1 方法设计

任务定义与情绪建模框架 在音乐情绪识别与推荐任务中，用户评论往往蕴含着丰富而细腻的情绪信息。与传统离散情绪分类（如快乐、悲伤、愤怒等）不同，本项目采用Valence–Arousal (VA) 连续情绪模型对文本情绪进行建模。

给定一段文本序列

$$x = \{w_1, w_2, \dots, w_n\},$$

文本情绪标注任务可形式化为一个回归问题，其目标是学习一个映射函数：

$$f(x) \rightarrow (v, a),$$

其中 v 表示情绪的愉悦度 (Valence)， a 表示情绪的唤醒度 (Arousal)。

采用VA 模型具有以下优势：

- 能够以连续方式刻画情绪强度，表达能力优于离散标签；
- 已被广泛应用于音乐情绪识别领域，便于与音频情绪建模任务对齐；
- 适合回归建模，能够自然刻画评论情绪的细微变化。

基于词典的情绪标注方法 作为基线方法，本项目首先尝试了基于情绪词典的文本情绪标注方式。该方法通过人工或半自动方式构建情绪词表，并为每个词分配对应的Valence 与Arousal 数值。在实际计算过程中，文本首先经过分词处理，随后根据词典查询每个词的情绪值，最终通过对词级情绪值进行加权平均或简单平均，得到句子级的VA 表示。尽管词典法实现简单、可解释性较强，但在实验过程中暴露出明显不足：

1. 缺乏对上下文语义的建模能力
词典法无法处理否定、转折等复杂语义结构，例如“并不开心”往往被错误地标注为高Valence。
2. 高度依赖词典覆盖率
面对网络用语、新词或隐喻表达时，词典法往往无法给出合理结果。
3. 无法建模情绪组合与句法关系
不同词语在句子中的相对位置和组合方式对整体情绪具有重要影响，而词典法对此完全忽略。

因此，词典法难以满足复杂评论文本情绪建模的需求，仅作为对比基线使用。

基于BERT 的情绪回归模型 为克服词典法的局限性，本项目采用基于Transformer 的深度学习方法，对文本情绪进行端到端建模。模型整体采用“预训练语言模型+ 回归头”的结构。具体而言，输入文本首先经过分词并转换为token 序列，随后送入预训练BERT 模型以获取上下文相关的语义表示。模型取[CLS] 标记对应的隐藏状态作为句子级表示，并通过多层感知机 (MLP) 回归头分别预测Valence 与Arousal 数值。

该模型能够充分利用大规模语料中学到的语言知识，从而捕捉文本中隐含的情绪语义。

4.2 实验设置

训练目标与优化策略 由于情绪预测属于连续值回归任务，本项目采用均方误差 (Mean Squared Error, MSE) 作为损失函数。对Valence 与Arousal 分别计算回归误差，其总损失定义为：

$$L = \text{MSE}(v_{\text{pred}}, v_{\text{true}}) + \text{MSE}(a_{\text{pred}}, a_{\text{true}}).$$

模型训练过程中使用AdamW 优化器，并在验证集上监控MSE 以及Pearson 相关系数，以评估模型对情绪趋势的拟合能力。

训练过程与可视化 模型训练脚本实现了完整的训练、验证与评估流程，并对训练损失、验证误差以及相关系数进行了可视化记录。通过观察训练曲线，可以验证模型是否出现过拟合或欠拟合现象，并为参数调节提供依据。

英文数据集: EmoBank 英文文本情绪建模部分采用EmoBank 数据集。该数据集提供句子级别的Valence、Arousal 和Dominance 标注，覆盖多种文本领域，是情绪维度建模领域的标准数据集之一。本项目选取其中的Valence 与Arousal 标注用于模型训练与评估。[4]

中文数据集构建: 离散情绪到VA 空间的映射 与英文数据相比，中文文本的VA 标注数据相对匮乏。为解决这一问题，本项目采用Ren_CECps 中文情绪数据集作为基础数据源。该数据集为文本提供七类离散情绪标签，包括愤怒、喜悦、悲伤、恐惧、厌恶、惊讶和平静。[5]

本项目根据情绪心理学理论，将上述离散情绪映射到VA 情绪空间中的不同区域，为每一类情绪分配对应的Valence 与Arousal 值，从而将分类问题转化为回归问题。通过该映射方式，构建了一个规模较大的中文文本-VA 情绪对齐数据集，为中文情绪回归模型的训练提供了有效支持。表2 给出了各情绪类别对应的Valence 与Arousal 数值设定。

Table 2 离散情绪类别到Valence–Arousal 空间的映射关系

情绪类别	Valence (<i>v</i>)	Arousal (<i>a</i>)	情绪特征描述
Love	1.0	0.6	极高愉悦，中高唤醒
Joy	0.8	0.7	高愉悦，高唤醒
Expect	0.5	0.4	中等愉悦，中等唤醒
Surprise	0.0	0.8	中性愉悦，高唤醒
Anxiety	-0.4	0.7	低愉悦，高唤醒
Anger	-0.8	0.8	极低愉悦，高唤醒
Sorrow	-0.7	-0.3	低愉悦，低唤醒
Hate	-1.0	0.6	极低愉悦，中高唤醒

该映射关系并非来源于人工连续标注，而是基于情绪心理学中对不同情绪在愉悦度与唤醒度维度上的一般认知进行设定。尽管该方法引入了一定程度的主观假设，但在缺乏大规模中文VA 标注数据的情况下，为情绪回归模型的训练提供了一种可行且可扩展的工程化解决方案。

4.3 结果与分析

训练结果分析 因为英文文本情绪识别模型训练结果与中文类似，因此这里以中文文本情绪识别模型为例，分别分析训练损失、验证MSE和验证Pearson相关系数与模型的关系。

1. 训练损失结果总结

如图2所示，训练损失曲线呈现持续、平稳的下降趋势：从初始阶段快速降低，中期速率放缓，最终在Epoch 10 收敛至0.05–0.06 的低区间，无震荡或回升。这表明模型有效学习了中文评论的情绪特征，BERT 架构与中文情绪回归任务的适配性良好，同时也验证了训练数据的情绪表达分布清晰、噪声较少，模型未出现过拟合或欠拟合问题，完成了情绪特征的高效学习。

2. 验证MSE 结果总结

如图3所示，验证MSE 按愉悦度、唤醒度维度拆分后，整体均随Epoch 单调下降并趋于稳定。定义MSE 为：

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

其中 y_i 为真实值， $\hat{y}_i$ 为预测值。最终愉悦度MSE 稳定在0.225–0.250 区间，唤醒度MSE 稳定在0.050–0.075 区间，且全程无反弹，说明模型对新评论数据的泛化能力良好。低且稳定的MSE 确保了同一音乐评论的情绪向量预测波动较小，能形成一致的监督标签，满足后续跨模态情绪对齐的误差控制需求；而唤醒度MSE 略低于愉悦度的差异，也反映了中文情绪表达中“激活程度”的语义辨识度更高。




Figure 2 训练损失




Figure 3 Validation MSE per Epoch

3. 验证Pearson 相关系数结果总结

如图4所示，验证Pearson 相关系数 r 呈现维度差异显著的特征。Pearson r 计算公式为：

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}.$$

愉悦度（蓝色曲线）全程维持在 $r \approx 0.75$ 的高相关水平，仅轻微波动，说明其预测结果与真实评论情绪的正负倾向高度契合；而唤醒度（橙色曲线）始终在 $r \in [0.55, 0.58]$ 区间波动，后期甚至略有下降，属于弱到中等相关。这一结果表明，愉悦度标签的真实有效性较强，可直接支撑后续任务；但唤醒度标签与真实情绪的关联较弱。

情绪归因分析 为了进一步理解模型的决策依据，本项目引入归因分析方法，对模型预测结果进行可解释性研究。通过计算文本中不同词语对Valence 与Arousal 输出的贡献度，可以分析模型在预测过程中关注的关键信息。 [6]




Figure 4 Validation Pearson r per

1. Valence / Arousal 解耦对比句

本实验选取了一组语义等价的中英文句子，其整体情绪特征为高Valence（积极情感）与相对较低的Arousal（低唤醒、平静状态）。基于已训练的中英文VA回归模型，采用Integrated Gradients (IG) 方法，对模型预测结果进行token-level attribution 分析，并分别可视化Valence 与Arousal 的归因热力图，以探究模型在跨语言场景下的情绪理解机制。我们分别选取中文句子“她安静地坐在窗边，脸上带着温柔而满足的微笑。”和英文句子“She sat quietly by the window, wearing a gentle and content smile.”进行分析。热力图结果如图5和图6所示。

经过分析，可以得到以下结论：

- 模型能够准确捕捉英语中表达积极情绪的核心情绪词，并在Valence 维度上形成集中、高强度的归因分布，体现出良好的情绪语义理解能力。
- 模型能够准确捕捉中文中表达积极情绪的核心情绪词，并在Valence 维度上形成集中、高强度的归因分布，体现出良好的情绪语义理解能力。
- 无论在中文还是英文中，模型都能准确将“平静的积极情绪”映射为高Valence、低Arousal，证明其并非简单的情绪分类器，而是具备连续情绪维度建模能力。

实验结果表明，所构建的中英文VA回归模型不仅能够准确预测句子的Valence 与Arousal 数值，还在token-level attribution 层面展现出高度一致的情绪理解模式。在高Valence、低Arousal 的语境下，模型在中英文中均将情绪权重集中分配于表达“温柔、满足、微笑”等核心情绪语义的词汇，而对功能词与场景描述赋予较低权重。这一现象表明模型并未依赖表层语言特征，而是学习到了跨语言一致的情绪语义表示，从而具备较强的可解释性与泛化能力。

2. 对于句子整体语意的理解

针对模型对于句子整体语意的理解能力的分析，本次实验选取了两组中英文语句进行token-level 归因分析，分别是语义等价的中英文转折句和中英文动作描述句。

语义等价的中英文转折句分别是“虽然他说着祝福的话，但语气里透着明显的冷漠。”和“Although he spoke words of blessing, his tone revealed clear indifference.”验证模型是否能突破“单个情绪词”的表层匹配，实现句级语义的整体情绪理解。热力图分别如图7和图8所示。

通过分析热力图，有以下结论：

- 模型未被单个正向词“blessing”误导，而是通过捕捉转折逻辑与核心负向词，实现了句级层面的负向情绪理解，验证了其超越“情绪词匹配”的语义整合能力。




Figure 5 高愉悦低唤醒中文语句




Figure 6 高愉悦低唤醒英文语句




Figure 7 有正向词，但整体情绪偏负的中文语句




Figure 8 有正向词，但整体情绪偏负的英文语句

- 中文模型同样能突破“祝福”这一正向词的干扰，通过句内语义冲突的整合，输出与整体情绪一致的负向Valence，证明其具备中文语境下的句级情绪理解能力。
- 中英文模型均能基于句级语义冲突，输出与“表面正向、实际负向”情绪匹配的中等唤醒度，证明其对复杂情绪状态的建模能力，而非仅依赖单个词的唤醒度标签。

实验结果表明，所构建的中英文VA回归模型具备句级语义主导的情绪理解能力：在“含正向词但整体偏负”的转折句中，模型未被单个正向词（如“blessing / 祝福”）误导，而是通过捕捉转折逻辑，将归因权重集中于核心负向词（“indifference / 冷漠”），最终输出与整体情绪一致的负向Valence；同时，模型能基于句内语义冲突，输出匹配情绪张力的中等Arousal。中英文模型在归因分布与语义整合模式上的高度一致性，进一步证明其学习到了跨语言通用的情绪语义表示，而非依赖表层情绪词的匹配，体现了良好的句级情绪理解能力与可解释性。

对于语义等价的中英文动作描述句（无显式情绪词，但通过动作/状态体现高唤醒），分别采用中文语句“他快步穿过人群，呼吸急促，额头冒着汗。”和“He rushed through the crowd, breathing heavily, sweat forming on his forehead.”

热力图如图9和图10所示。分析如下：

- 模型未依赖显式情绪词，而是通过“急促呼吸、快步穿行”等动作的语义，捕捉到句子隐含的弱负向情绪，体现了超越“情绪词匹配”的语义理解能力。
- 中文模型同样能通过动作/状态的语义整合，识别无显式情绪词句子的弱负向情绪，证明其具备基于场景动作的情绪推理能力。
- 中英文模型均能在无显式情绪词的情况下，通过动作/状态的语义整合，准确识别句子的高唤醒特征，证明其具备“动作-情绪状态”的关联推理能力，而非仅依赖情绪词的唤醒度标签。

实验结果表明，所构建的中英文VA回归模型具备无显式情绪词下的句级情绪推理能力：在“仅含动作/状态描述、无情绪词”的句子中，模型未依赖表层情绪词匹配，而是通过“快步穿行、急促呼吸、额头冒汗”等动作/状态的语义整合，输出与“紧张/急切”状态一致的“弱负Valence + 高Arousal”；且中英文模型的归因均集中于动作/状态核心词，呈现高度一致的推理模式。这一结果证明模型学习到了“动作-情绪状态”的抽象关联，能够突破显式情绪词的限制，实现基于句级语义的情绪理解，体现了良好的泛化性与可解释性。




Figure 9 无情绪词，但整体高唤醒的中文语句

3. 中英同义句attribution 对齐

本实验选取语义等价的中英文正向情绪句（含“激动、喜悦”等显式情绪词），基于训练完成的中英文VA回归模型，采用Integrated Gradients (IG)方法进行token-level归因分析，可视化Valence（愉悦度）与Arousal（唤醒度）热力图，验证模型在显式情绪词场景下的归因焦点、语义分工及跨语言对齐性。

中文句子为“我终于实现了多年来的梦想，内心充满了激动与喜悦。”，英文句子为“I finally achieved my long-held dream, filled with excitement and joy.”，热力图分析如图11和图12所示。分析如下：

- 中英文模型的归因焦点高度对齐——均将显式情绪词（excitement / 激动、joy / 喜悦）作为Valence与Arousal的高亮核心，同时对功能词/非情绪词赋予近0贡献，证明模型在跨语言场景下对“情绪词-非情绪词”的区分能力一致。




Figure 10 无情绪词，但整体高唤醒的英文语句

- 中英文模型的Valence与Arousal分工模式高度一致——Valence由所有正向情绪词共同驱动，Arousal则更聚焦于“激动”类高唤醒情绪词，证明模型在跨语言场景下对“情绪极性（Valence）- 情绪强度（Arousal）”的维度解耦逻辑一致。

实验结果表明，所构建的中英文VA回归模型在显式情绪词场景下，呈现出高度一致的归因焦点与维度分工模式：跨语言层面，模型均将“excitement / 激动、joy / 喜悦”等显式情绪词作为Valence与Arousal的高亮核心，同时对功能词、非情绪词赋予近0贡献；维度分工层面，Valence由所有正向情绪词共同驱动，而Arousal更聚焦于“激动”类高唤醒情绪词，这一逻辑在中英文模型中完全对齐。该结果证明模型学习到了跨语言通用的“情绪词- 情绪维度”关联模式，并非依赖单语言的表层特征，而是具备抽象的情绪语义理解与维度解耦能力，为跨语言情绪分析任务提供了可靠的可解释性支撑。




Figure 11 中文attribution对齐




Figure 12 英文attribution对齐

模型可解释性 综合多组中英文语义等价句的归因分析实验，所构建的VA回归模型在情绪理解能力、跨语言泛化性、维度建模合理性三个核心维度均展现出充分的可行性：

- 情绪理解能力：突破表层特征，实现句级语义推理 模型既能够在“含正向词但整体负向”的转折句中，通过语义冲突整合输出与整体情绪一致的结果；也能在“无显式情绪词”的动作描述句中，通过动作/状态的

关联推理识别高唤醒特征；同时在显式情绪词句中，精准聚焦情绪词并区分其对Valence与Arousal的不同贡献——证明模型具备超越“词级匹配”的句级语义理解能力，可有效处理复杂情绪场景。

2. 跨语言泛化性：抽象语义对齐，不受语言表层差异影响 中英文模型在归因焦点（高亮情绪词/近0非情绪词）、维度分工（Valence与Arousal的语义分配逻辑）上高度一致，即使词法、句法存在显著差异，仍能形成跨语言通用的情绪理解模式——说明模型学习到了“语言无关”的抽象情绪语义表示，具备跨语言情绪分析的泛化可行性。
3. 维度建模合理性：Valence-Arousal解耦，匹配情绪认知逻辑 模型在所有实验中均体现出“Valence（情绪极性）与Arousal（情绪强度）的解耦建模”：例如“喜悦”驱动Valence但对Arousal贡献弱，“激动”同时驱动Valence与Arousal——这一分工与人类情绪认知的维度逻辑一致，证明模型的情绪维度建模具备理论与实践层面的合理性。

综上，该VA回归模型能够可靠、泛化地完成跨语言文本情绪的Valence-Arousal预测，且具备清晰的可解释性，完全满足文本情绪识别任务的核心需求，在实际场景中具备良好的应用可行性。

5 跨模态情绪对齐与推荐模块

本模块的目标是在用户主观情绪表达与音乐客观情绪特征之间建立统一的情绪坐标体系，并在此基础上实现情绪共鸣型与情绪调节型音乐推荐。系统以Valence-Arousal (VA) 二维连续空间作为跨模态对齐的公共语义坐标系，使文本、音乐与推荐策略可以在同一几何空间内进行运算与决策。

5.1 方法设计

文本到情绪空间的跨模态映射 用户通过自然语言输入其当前心理状态（如“今天有点压抑”“很焦虑”），后端采用基于BERT / RoBERTa 的情绪回归模型输出原始情绪值 $(V_{\text{raw}}, A_{\text{raw}}) \in [0, 1]^2$ 。为了与音乐情绪回归模块的坐标体系保持一致，系统采用线性变换将其映射到对称区间 $[-1, 1]$ ：

$$V = (V_{\text{raw}} - 0.5) \times 2, \quad A = (A_{\text{raw}} - 0.5) \times 2. \quad (1)$$

该映射保证了文本语义空间与音乐情绪空间在几何意义上的可比性，从而实现真正的跨模态对齐。

多模式情绪引导策略 在统一的VA空间中，系统设计了三种可切换的推荐模式：

- 自适应模式（Auto）：系统根据用户当前坐标 (V_u, A_u) 自动判断其心理状态。当 $V_u < -0.2$ （低愉悦）时，将目标点设定为治愈区 $(0.5, -0.4)$ ；当 $A_u > 0.5$ （高唤醒）时，引导至放松区 $(0.2, -0.6)$ 。
- 陪伴模式（Companion）：以情绪共鸣为目标，将推荐目标设定为用户当前点 (V_u, A_u) 本身，从而优先选择最“懂你”的音乐。
- 治愈模式（Regulate）：用于主动心理干预，直接将目标点设定为 $(0.8, -0.6)$ ，即高愉悦、低唤醒的稳定情绪区。

显著性加权匹配机制 对任一音乐 i ，其情绪坐标为 (V_i, A_i) 。与目标点 (V_t, A_t) 的欧氏距离为

$$D_i = \sqrt{(V_i - V_t)^2 + (A_i - A_t)^2}. \quad (2)$$

同时定义音乐的情绪显著性（模长）为

$$M_i = \sqrt{V_i^2 + A_i^2}. \quad (3)$$

最终采用加权距离：

$$\text{Score}_i = D_i - 0.18M_i, \quad (4)$$

该机制在保证接近目标情绪的前提下，优先推荐情绪表达更强烈、更“有性格”的音乐，从而避免中性和平庸曲目的主导。

5.2 实验设置

匹配度度量 系统定义情绪匹配百分比作为推荐质量指标:

$$\text{Match} = (2.0 - \text{AdjustedDist}) \times 50, \quad (5)$$

其中AdjustedDist 为显著性加权后的距离, 匹配值越高表示音乐与目标情绪越接近。

候选池生成策略 在包含数千首音乐的混合曲库(公有数据集+用户私有库)中, 系统采用改进KNN搜索目标点的Top-15最近邻构成候选池, 并从中随机抽取5首进行展示, 从而在准确性与多样性之间取得平衡。

情绪轨迹动画 GUI中设定插值步数 $N = 12$, 将用户情绪点到目标点的迁移表示为

$$\mathbf{p}_k = \mathbf{p}_0 + \frac{k}{N}(\mathbf{p}_t - \mathbf{p}_0), \quad k = 1, \dots, N, \quad (6)$$

实现平滑的情绪引导动画。

5.3 结果与分析

可视化结果表明, 不同风格音乐在VA空间中形成良好的象限覆盖(私有库与公有库分布可分离但互补), 证明情绪表征具有稳定判别性。通过get_emotion_tag生成的文本反馈与实际推荐方向保持一致, 有效解决了文本与音频之间的语义断层问题。

6 系统整合与可视化展示 (GUI)

本系统通过Tkinter将深度学习推理、情绪空间计算与用户交互进行一体化封装, 构建了可视化的音乐情绪调节平台。

6.1 界面布局

系统界面采用分栏卡片式结构: 左侧为情绪输入区与推荐模式切换区, 右侧上方为VA空间散点图, 下方为推荐结果列表。




Figure 13 系统主界面与VA空间可视化。

6.2 私有音乐库管理

系统提供批量上传与分析窗口，自动生成用户专属情绪数据集[username]_dataset.csv，并支持可视化编辑与增量学习。




Figure 14 用户私有音乐库分析与管理界面。

6.3 可解释性与反馈

系统通过匹配度进度条（Score Bar）与实时日志窗口向用户展示推荐逻辑与运行状态，提高了情绪推荐过程的透明度与可信度。



Figure 15 推荐结果与情绪匹配度可视化。

7 总结与展望

本文围绕“基于情绪的音乐推荐”这一问题，构建了一套以Valence–Arousal（VA）模型为核心的跨模态情绪感知与推荐系统。通过将音乐情绪识别、文本情绪分析以及情绪空间中的推荐策略进行统一建模，系统实现了从用户自然语言输入到音乐情绪调节输出的完整闭环。在工程实现上，本项目不仅完成了音频与文本两种模态的情绪回归模型，还通过统一的VA空间完成了跨模态对齐，并借助可视化GUI将这一过程转化为可交互、可理解的用户体验。

在音乐情绪识别方面，系统通过深度卷积网络与多专家回归结构，实现了对音乐愉悦度与唤醒度的连续预测，并支持用户私有音乐库的批量分析与情绪标注；在文本情绪识别方面，模型能够从用户自然语言中提取情绪强度并映射到VA坐标，同时提供词级权重用于解释；在跨模态推荐层面，通过引入情绪目标点、显著性加权距离以及多种推荐模式，系统实现了“情绪共鸣”与“情绪调节”两类不同心理目标的统一建模。GUI模块进一步将这些抽象的情绪计算结果转化为二维平面中的动态轨迹与直观反馈，使情绪驱动的推荐逻辑对用户可见、可理解。

尽管系统已经实现了较为完整的功能闭环，但仍存在若干值得进一步研究和优化的方向。首先，在情绪建模方面，当前VA预测仍依赖有限规模的数据集和自动标注策略，未来可以引入更大规模、更高质量的人工标注情绪音乐与文本数据，以提升模型的泛化能力和细粒度表达能力。其次，在跨模态对齐层面，目前采用的是基于几何距离与规则设定的情绪调节策略，后续可以探索基于强化学习或用户反馈的自适应策略，使系统能够根据用户长期行为自动学习最合适的情绪引导路径。

在应用层面，本系统目前主要面向单次情绪输入与即时推荐，未来可以扩展为“情绪轨迹建模”，对用户在不同时间维度上的情绪变化进行建模，从而实现更加个性化、长期化的音乐陪伴与心理调节。此外，该框架本身并不局限于音乐场景，还可以拓展至影视推荐、心理辅导、智能陪伴等多种情绪感知应用领域。

总体而言，本项目验证了以VA情绪空间为核心进行跨模态情绪建模与推荐的可行性，并通过完整的系统实现展示了其工程与交互价值，为情绪感知型智能推荐系统的进一步研究与应用提供了有力的参考。

8 小组分工

References

- [1] D. Han, Y. Kong, J. Han, and G. Wang, “A survey of music emotion recognition,” *Frontiers of Computer Science*, vol. 16, no. 6, pp. 1663–1702, 2022.
- [2] A. R. Mahmud *et al.*, “A review on emotion detection from text: Opportunities and challenges,” *Trends in Electronics and Health Informatics Proceedings*, 2024.
- [3] R. Liyanarachchi, A. Joshi, and E. Meijering, “A survey on multimodal music emotion recognition,” *arXiv preprint*, 2025. arXiv:2504.18799.
- [4] S. Buechel and U. Hahn, “EmoBank: Studying the impact of annotation perspective and representation format on dimensional emotion analysis,” in *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 2, Short Papers* (M. Lapata, P. Blunsom, and A. Koller, eds.), (Valencia, Spain), pp. 578–585, Association for Computational Linguistics, Apr. 2017.
- [5] C. Quan and F. Ren, “Construction of a blog emotion corpus for chinese emotional expression analysis,” in *Proceedings of the 2009 Conference on Empirical Methods in Natural Language Processing: Volume 3 - Volume 3*, EMNLP '09, (USA), p. 1446–1454, Association for Computational Linguistics, 2009.
- [6] M. Sundararajan, A. Taly, and Q. Yan, “Axiomatic attribution for deep networks,” in *Proceedings of the 34th International Conference on Machine Learning - Volume 70*, ICML'17, p. 3319–3328, JMLR.org, 2017.